Reconocimiento automático de platos de comida para la estimación de información nutricional

Por: Juan Esteban Orrego

1. Objetivos

Problema. El registro manual de la ingesta alimentaria es tedioso y poco preciso, lo que dificulta el seguimiento de hábitos nutricionales. Reconocer automáticamente el plato a partir de una fotografía puede apoyar aplicaciones de salud y control dietético. El reto es de clasificación de imágenes: identificar, entre varias categorías de comida, cuál aparece en la foto.

Objetivo general. Desarrollar un modelo de clasificación de imágenes basado en redes neuronales convolucionales y transfer learning, capaz de identificar 34 categorías de platos de comida populares a partir de una fotografía, asociando cada predicción a su información nutricional de referencia (calorías y macronutrientes).

Objetivos específicos. (1) Preparar y analizar un subconjunto de 34 clases del dataset Food-101, con preprocesamiento, aumento de datos y división en entrenamiento/validación/prueba. (2) Entrenar y optimizar un modelo mediante transfer learning sobre una CNN preentrenada, evaluándolo con accuracy y F1-score. (3) Evaluar la generalización sobre imágenes externas no vistas y vincular cada predicción con su información nutricional (**USDA FoodData Central**).

2. Base de datos

Se utilizó **Food-101** (Bossard et al., 2014), dataset público de 101 categorías de comida con 1.000 imágenes cada una. Se seleccionó un subconjunto de **34 clases** de comidas populares y con contraste nutricional (hamburguesa, pizza, sushi, ensaladas, sopas, postres, etc.), resultando en 34.000 imágenes.

Preprocesamiento. Las imágenes se redimensionaron a 224×224 px y se normalizaron con la media y desviación de ImageNet, requisito al usar un modelo preentrenado en ese dataset.

Aumento de datos (solo en entrenamiento): recorte aleatorio, volteo horizontal, rotación (±15°) y jitter de color. Aumenta la variabilidad y reduce el sobreajuste; no se aplica en validación/prueba para medir de forma realista.

División. Partición estratificada: 70% entrenamiento (23.800), 15% validación (5.100) y 15% prueba (5.100). La validación selecciona el mejor modelo y la prueba evalúa sobre datos no vistos.

3. Modelo

Se empleó **EfficientNet-B0** (Tan & Le, 2019) preentrenado en ImageNet, mediante transfer learning. Esta arquitectura introduce el compound scaling (escalado equilibrado de profundidad, ancho y resolución), logrando alta precisión con pocos parámetros (~4 M), apropiada para entrenar con recursos limitados.

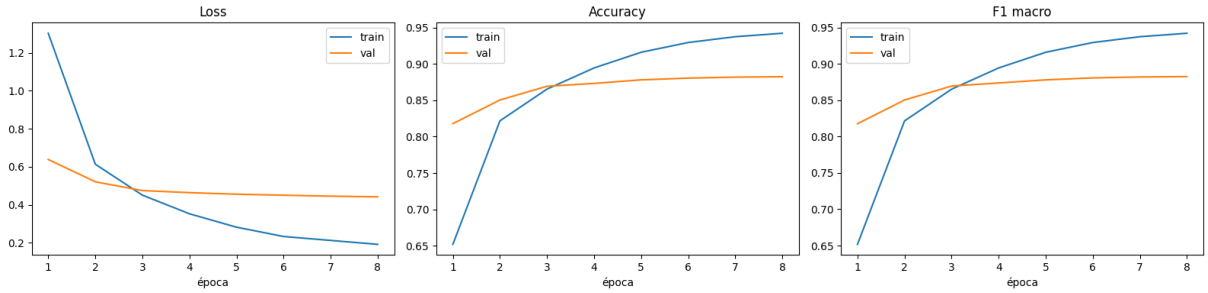
Decisiones de implementación. Se conservó el backbone convolucional preentrenado y se reemplazó solo la capa de clasificación final (de 1.000 clases de ImageNet a 34 de comida). El entrenamiento usó learning rate diferenciado (menor en el backbone, mayor en la cabeza), pérdida CrossEntropy, optimizador AdamW con weight decay, scheduler coseno y precisión mixta (AMP). Se entrenó 8 épocas con batch de 64, conservando el mejor modelo según el F1 de validación. La tasa de aprendizaje diferenciada (1e-4 en el backbone, 1e-3 en la cabeza) evita destruir los pesos preentrenados —que ya codifican características visuales útiles— mientras permite que la nueva capa de clasificación aprenda más rápido. El batch de 64 aprovecha la memoria de la GPU T4 sin desbordarla. Se eligieron 8 épocas porque la validación se estabiliza alrededor de la época 6-7, evitando entrenar de más.

Recursos. Entrenamiento en Kaggle con GPU Tesla T4; tiempo total ~37,6 minutos.

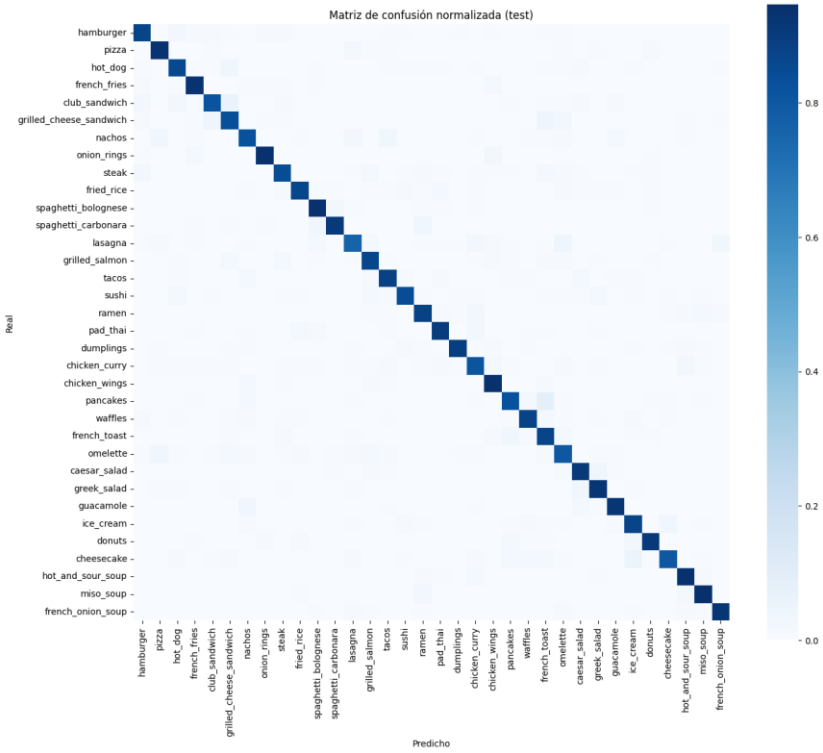
4. Resultados

Desempeño en prueba. El modelo alcanzó 88,0% de accuracy y 0,88 de F1 macro sobre 5.100 imágenes no vistas. Que ambas métricas coincidan refleja el balance del dataset (150 imágenes por clase).

Curvas de aprendizaje. El F1 de validación sube de 0,82 a 0,88 y se estabiliza; desde la época 5 aparece un sobreajuste leve (F1 de entrenamiento 0,94 vs. validación 0,88), moderado y esperable en fine-tuning.



Por clase. Mejor desempeño en platos distintivos (onion_rings 0,95; miso_soup 0,93; carbonara 0,93). Peor en platos que se confunden con similares (omelette 0,78; lasagna 0,80; french_toast 0,81). La matriz de confusión concentra los errores entre comidas visualmente cercanas.



Generalización (datos externos). Se evaluó con 5 fotografías externas ajenas al dataset. Acertó 3 de 5 (60%): pizza, hamburguesa y aros de cebolla, con alta confianza. Los dos errores (papas 'cargadas' clasificadas como arroz frito, y una foto con varios perritos calientes clasificada como si fuera un omelette) ocurrieron con baja confianza y en imágenes compuestas o atípicas. La caída de 88% a 60% evidencia la brecha de dominio: las fotos externas difieren en iluminación, ángulo y encuadre respecto a Food-101.

Información nutricional. Cada predicción se vincula con sus macros por 100 g (kcal, proteína, grasa, carbohidratos) obtenidos de **USDA FoodData Central**. La red solo clasifica; los valores nutricionales provienen de una fuente oficial, manteniendo el criterio objetivo.

5. Conclusiones

Se cumplieron los objetivos: un clasificador de 34 platos con transfer learning que alcanza 88% de accuracy en prueba y se integra con información nutricional de referencia. Los aciertos se concentran en platos distintivos y los errores en comidas visualmente similares, patrón coherente en prueba y en datos externos. El modelo generaliza aceptablemente a imágenes claras, pero su desempeño se degrada ante platos compuestos o presentaciones atípicas, limitación propia de entrenar sobre un único dataset. Mejoras futuras: ampliar los datos con dominios variados, aplicar regularización adicional o early stopping, explorar arquitecturas mayores (EfficientNet-B3) y estimar la porción para una estimación nutricional más precisa.

Referencias: Bossard, L., Guillaumin, M. & Van Gool, L. (2014). Food-101 – Mining Discriminative Components with Random Forests. ECCV. · Tan, M. & Le, Q. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. ICML.